# 강화학습 기반 자율주행에서 안정성과 효율성 향상을 위한 Human-in-the-Loop 도입 연구

RAILab

김한재, 김성환, 장태현, 송호영, 이예진, 이현욱, 김현석(교수)
동아대학교 컴퓨터AI공학부

## 연구 요약

**자율주행에 강화학습을 적용할 때 초기 단계에서 비효율적이고 위험한 행동이 반복되어 실제 환경 적용에 제약이 따른다. 본 연구는 이를 해결하기 위해 Human-in-the-Loop(HIL) 방식을 도입하고, Soft Actor-Critic(SAC) 알고리즘에 사람의 제어 입력을 반영하였다. 사람의 조작과 에이전트의 행동을 가중 평균해 최종 행동을 결정하며, 개입 비중(α)은 점차 줄어든다. 이를 통해 안정적인 데이터 수집과 자율 학습 전환을 유도하고, HIL 구조의 성능과 학습 안정성을 SAC와 비교해 분석하였다.**

## 알고리즘 설계

**Algorithm 1:** Human-in-the-Loop Soft Actor-Critic (HIL-SAC) for CarRacing

Initialize actor network $\theta$, critic network $\phi$
Initialize replay buffer $\mathcal{D} \leftarrow \emptyset$
Set human intervention limit $H$ (e.g., 50,000 steps)
Set blending factor $\alpha \leftarrow 0.9$
Reset environment: $s_0 \sim Env$
**for** $t = 1$ **to** $T$ **do**
  Observe state $s_t$
  Predict agent action $a_t^A \leftarrow \pi_\theta(s_t)$
  **if** $t < H$ ***and*** *human is intervening* **then**
    Get human action $a_t^H$
    Blend action: $a_t \leftarrow \alpha \cdot a_t^H + (1-\alpha) \cdot a_t^A$
    Decay $\alpha$ over time
  **else**
    $a_t \leftarrow a_t^A$
  Execute $a_t$ in environment $\rightarrow$ observe $r_t$, $s_{t+1}$, done
  Store transition $(s_t, a_t, r_t, s_{t+1}, done)$ in $\mathcal{D}$
  **if** *human intervened* ***and*** $t \bmod 1000 = 0$ **then**
    Sample batch from $\mathcal{D}$
    Train SAC model using gradient updates
  **if** *done* **then**
    Reset environment
**Post-Human Training Phase:**
Train SAC model on $\mathcal{D}$ for extended steps

**Figure 1. Pseudocode of the SAC+HIL algorithm**

**Figure 1은 사람이 개입해 강화학습을 돕는 알고리즘 흐름을 보여준다. 초기에는 사람이 자동차를 조작하고, 에이전트의 예측과 혼합해 동작에 반영한다. 사람의 비중은 점차 줄고 에이전트가 자율적으로 판단한다. 개입 중에는 주기적으로 모델을 업데이트하며, 이후 수집된 데이터로 에이전트가 단독 학습을 이어간다. 이 알고리즘은 기존 강화학습에 사람의 도움을 자연스럽게 결합하도록 설계되었다.**

## SAC vs HIL-SAC 성능 분석

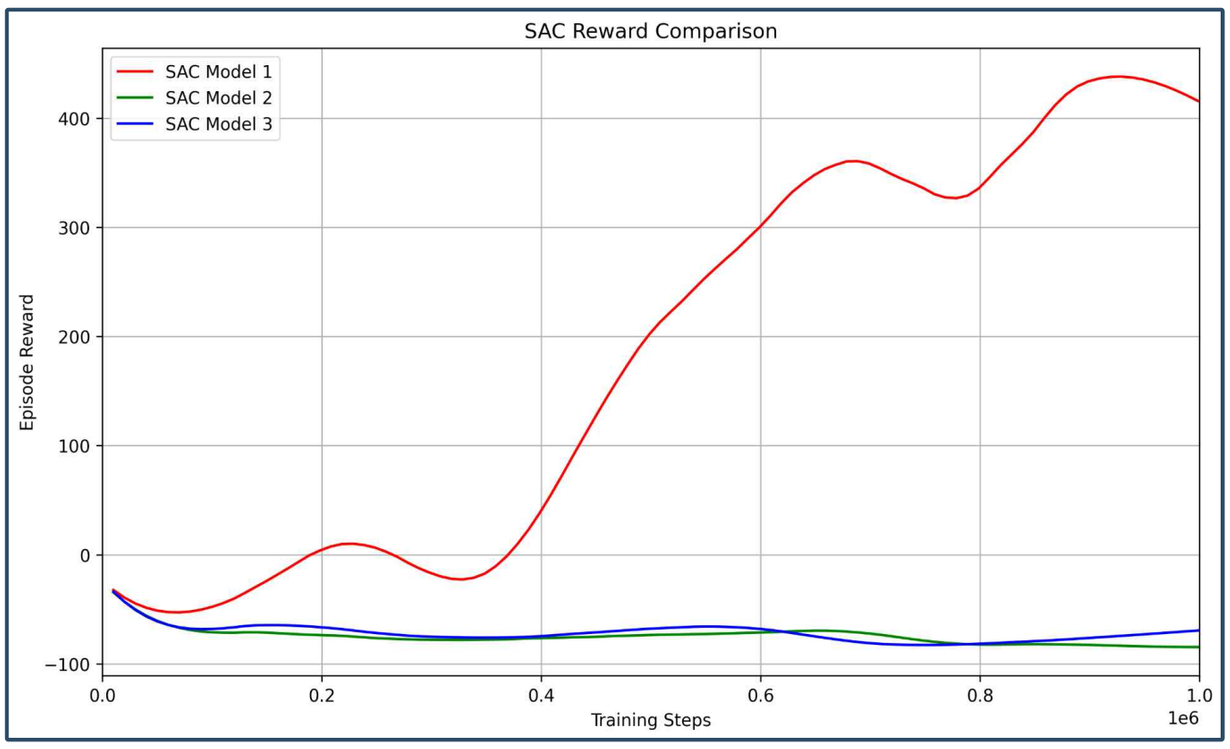


**Figure 2. Performance comparison of SAC models**

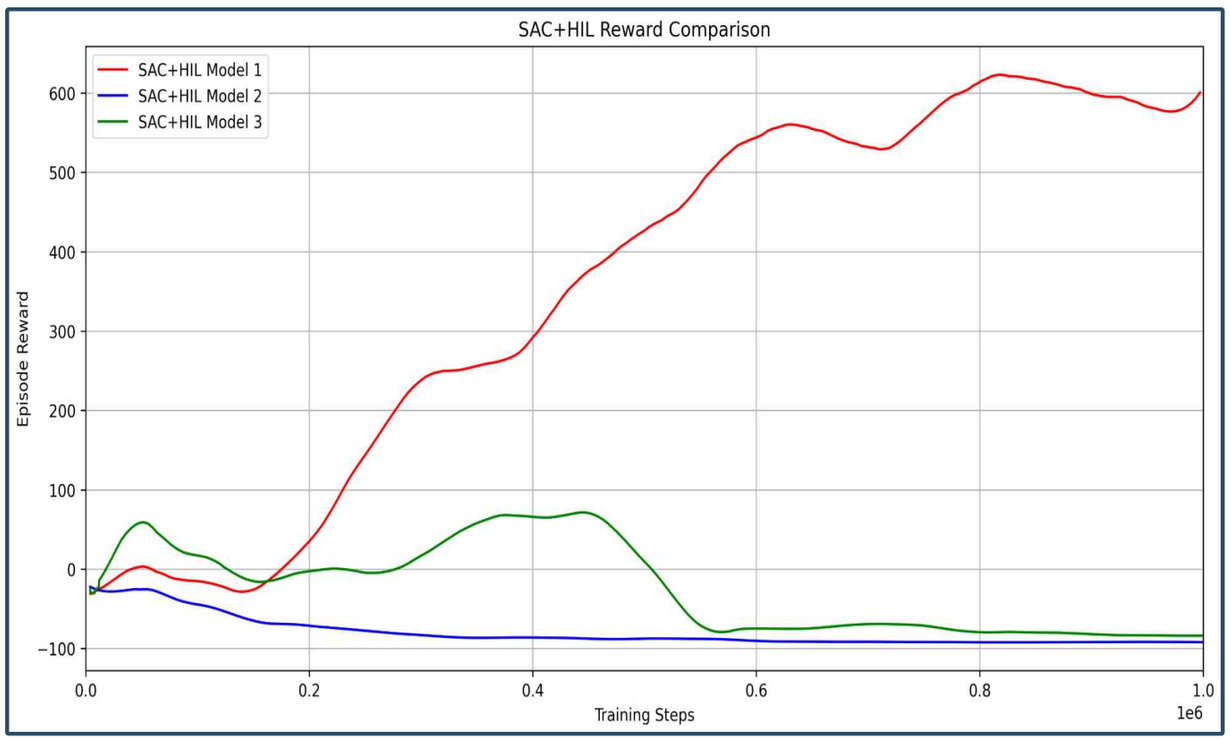


**Figure 3. Performance comparison of SAC+HIL models**

## 강화학습 기반 자율주행 실험 화면

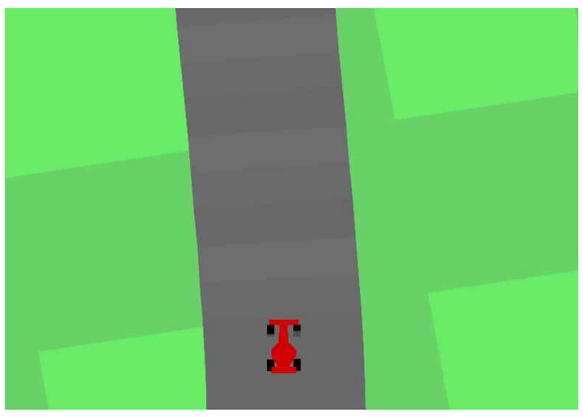

**Straight**

**Curve**

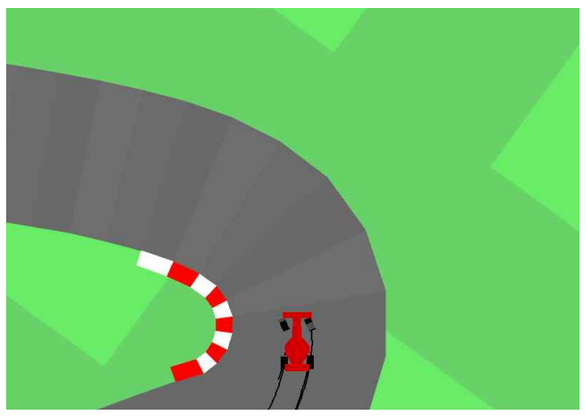

**Hairpin turn**

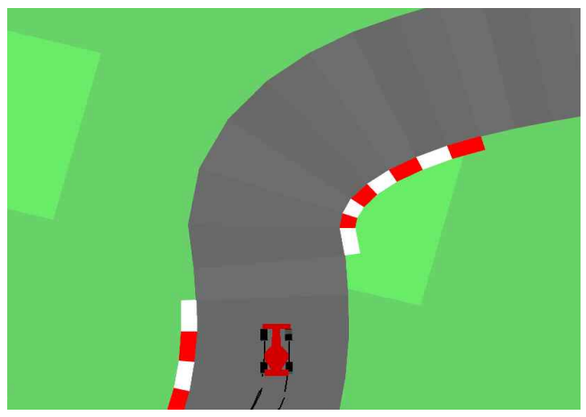

**S-curve**

## 연구 결론

**SAC과 SAC+HIL을 비교한 결과, SAC+HIL 구조는 일부 실험에서 더 빠른 수렴과 높은 리워드를 보여 학습 초반 안정성 향상에 긍정적인 효과를 보였다. 그러나 성능이 일관되게 향상되지는 않았고, 일부 실험에서는 낮은 보상 구간에 정체되거나 수렴 실패가 관찰되었다. 이는 개입 데이터가 일반 경험과 함께 학습되면서 효과가 희석되었거나, 개입이 충분한 학습 신호를 제공하지 못했기 때문으로 분석된다. 향후 개입 데이터를 명시적으로 구분하거나 우선 반영하는 샘플링 전략과 개입 효율을 동적으로 평가하는 기제를 결합해 학습 구조를 개선할 계획이다.**