강화학습 기반 자율주행에서 안정성과 효율성 향상을 위한 Human-in-the-Loop 도입 연구

김한재, 김성환, 장태현, 송호영, 이예진, 이현욱, 김현석*
동아대학교 컴퓨터공학과
e-mail : 2024482@donga.ac.kr, seonghwan66@donga.ac.kr,
2571386@donga.ac.kr, thdghdud317@donga.ac.kr, yeajin2100@donga.ac.kr,
2342849@donga.ac.kr, hertzkim@dau.ac.kr*

Evaluating Human-in-the-Loop Integration in RL-Based Autonomous Driving for Stability and Efficiency

Han-Jae Kim, Seong-Hwan Kim, Tae-Hyeon Jang, Ho-Young Song,
Ye-Jin Lee, Hyeon-Uk Lee, Hyun-Seok Kim*
Dept of Computer and AI Engineering, Dong-A University

요 약

자율주행의 효율성과 안정성 향상을 위해 Human-in-the-Loop 방식을 도입하고, 사람의 개입 데이터를 SAC 기반 강화학습에 반영하여 CarRacing 환경에서 에이전트의 주행 성능을 개선하고자 하였다.

1. 서론

최근 자율주행 기술은 빠르게 발전하고 있지만, 여전히 안정성과 효율성 측면에서 다양한 도전 과제를 안고 있다. 특히 자율주행 시스템에 강화학습을 적용할 경우, 초기 학습 단계에서 에이전트가 비효율적이거나 위험한 행동을 반복적으로 시도하는 문제가 자주 발생한다 [1][2]. 이는 실제 환경에서 적용하기 어려운 큰 한계로 작용하며, 강화학습의 실용성을 저해하는 요인 중 하나다.

본 연구에서는 이러한 문제를 해결하고자, 초기 안정성이 낮은 강화학습 과정에 실시간으로 인간이 개입하여 에이전트의 학습을 돕는 Human-in-the-Loop(HIL) 방식을 도입하였다 [3][4]. 단순히 강화학습의 성능 향상뿐만 아니라, 비효율적 행동을 조기에 교정함으로써 전체 학습 효율을 높이고 안정성을 확보하는 것을 목적으로 한다.

이때 강화학습 알고리즘으로는 Soft Actor-Critic(SAC) 방식을 채택하였으며 [5], 이 위에 HIL 구조를 통합하는 형태로 알고리즘을 구현하였다. SAC는 연속적인 액션 공간에서 높은 성능을 보이지만, 초기 탐색 과정에서 불안정한 행동이 잦다는 단점이 있다 [6]. 이에 따라 SAC 구조 내에서 사람이 직접 에이전트의 행동을 선택하거나 우선적으로 반영할 수 있도록 설계하였다.

이러한 구조를 통해 사람이 개입한 데이터를 중심으로 학습을 유도하고, 이후에는 스스로 효율적인 경로를 탐색하도록 유도하는 방식으로 학습을 수행하였다. 본 논문에서는 이러한 HIL 기반 강화학습 구조가 실제로 SAC 대비 성능을 얼마나 개선할 수 있는지, 그리고 학습 안정성 측면에서 어떤 영향을 주는지를 실험을 통해 분석하였다.

2. 관련연구

강화학습의 안정성과 효율성을 높이기 위한 HIL방식은 다양한 형태로 제안되어 왔다. 기존 연구에서는 사람이 사전에 데이터를 수집해 imitation learning 방식으로 활용하거나, 학습 중간에 preference-based feedback을 통해 보상을 조정하는 방식 등이 주로 사용되었다[7][8]. 이들 대부분은 사람의 개입이 강화학습 과정에서 보조적이거나 간접적인 형태로 적용되었다.

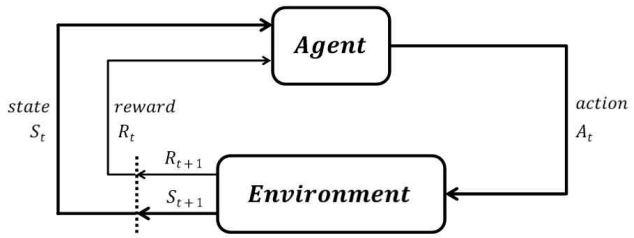

그림 1. 강화학습 구조
Figure 1. Reinforcement Learning structure

일부 연구에서는 개입 데이터를 별도로 분리하거나, 강화학습의 학습 구조 자체를 수정하여 학습 흐름을 제어하는 방식을 채택하기도 했다. 그러나 이와 같은 구조는 구현이 복잡하거나 일반적인 강화학습 환경에 적용하기 어렵다는 한계를 가진다.

본 연구는 Stable-Baselines3의 SAC 학습 구조를 활용하여, 사람 개입 데이터를 에이전트의 일반 경험과 함께 replay buffer에 저장하고 학습에 반영하였다. 이를 통해 강화학습 과정에 사람의 개입을 유기적으로 통합하는 방식의 효과를 실험적으로 분석하였다.

3. 알고리즘 설계

본 연구에서는 자율주행 시뮬레이터인 CarRacing 환경에 강화학습 알고리즘인 SAC을 적용하고, 여기에 HIL 방식을 결합하여 초기 학습 안정성과 전체적인 학습 효율을 향상시키는 알고리즘을 구성하였다. 전체 알고리즘의 흐름은 [그림 2]의 의사코드에 제시되어 있으며, Stable-Baselines3 프레임워크를 기반으로 구현하였다.

Algorithm 1: Human-in-the-Loop Soft Actor-Critic (HIL-SAC) for CarRacing

```
Initialize actor network θ, critic network φ
Initialize replay buffer D ← ∅
Set human intervention limit H (e.g., 50,000 steps)
Set blending factor α ← 0.9
Reset environment: s_0 ~ Env
for t = 1 to T do
    Observe state s_t
    Predict agent action a_t^A ← π_θ(s_t)
    if t < H and human is intervening then
        Get human action a_t^H
        Blend action: a_t ← α · a_t^H + (1 − α) · a_t^A
        Decay α over time
    else
        a_t ← a_t^A
    Execute a_t in environment → observe r_t, s_{t+1}, done
    Store transition (s_t, a_t, r_t, s_{t+1}, done) in D
    if human intervened and t mod 1000 = 0 then
        Sample batch from D
        Train SAC model using gradient updates
    if done then
        Reset environment
Post-Human Training Phase:
Train SAC model on D for extended steps
```

그림 2. SAC+HIL 알고리즘의 의사코드

Figure 2. Pseudocode of the SAC+HIL algorithm

초기 학습 단계에서는 탐험 과정에서 에이전트가 비효율적이거나 위험한 행동을 수행하는 것을 완화하기 위해, 사용자의 수동 제어 입력이 허용되도록 설계하였다. 사람은 조향, 가속, 제동을 실시간으로 제어할 수 있으며, 이때 에이전트가 예측한 행동과 사람의 조작을 가중 평균하여 최종 행동을 결정한다. 혼합 방식은 다음과 같이 정의한다.

$$a_t = \alpha \cdot \mathrm{a}_t^{\mathrm{human}} + (1-\alpha) \cdot \mathrm{a}_t^{\mathrm{agent}}$$

여기서 a_t^{human}는 사람이 제어한 행동, a_t^{agent}는 에이전트가 예측한 행동이며, α는 사람 개입의 가중치를 의미한다. 초기에는 α=0.9로 설정되어 대부분의 행동이 사람에 의해 결정되며, 학습 step이 증가함에 따라 α는 선형적으로 감소하고, 최대 개입 50,000 step에 도달하면 0에 수렴한다. 이러한 구조는 학습 초기에 안정적인 데이터 수집을 유도하면서도, 점차 에이전트가 스스로 학습을 이어나갈 수 있도록 유도한다.

기존의 HIL 기반 연구에서는 개입 데이터를 별도로 저장하거나 학습 구조를 수정하는 경우가 많았으나, 본 연구에서는 구조적인 변경 없이 기존 SAC 구조를 유지한 채, 에이전트의 경험과 사람 개입 데이터를 동일한 replay buffer에 통합하여 저장하는 방식을 채택하였다. 이를 통해 구현 복잡도를 줄이고, 일반적인 강화학습 프레임워크 내에서의 적용 가능성을 높였다.

사람이 개입한 경우에는 일정 주기마다 학습을 수행하여 개입된 행동이 정책에 빠르게 반영될 수 있도록 구성하였다. 구체적으로는 사람이 조작을 수행하고 매 1,000 step마다, SAC 모델을 1,000 step 학습시켜 replay buffer에 저장된 데이터를 기반으로 즉각적인 정책 수정을 유도하였다.

사람의 개입이 종료된 이후에는 추가적으로 50,000 step에 걸쳐 기존 데이터를 바탕으로 학습을 진행하여 안정적인 학습 전환을 도모하였으며, 이후 총 900,000 step의 본 학습을 통해 최종 성능을 비교하였다. 이와 같은 학습 구조는 개입 기반의 초반 안정성과 에이전트의 자율성을 모두 확보할 수 있도록 설계하였다.

4. 실험 및 결과

SAC+HIL 구조와 기존 SAC 알고리즘을 동일한 조건에서 비교하고, 실험을 통해 얻은 결과를 분석하였다. 실험은 CarRacing-v3 환경을 사용하였으며, 모든 실험에는 동일한 시드를 적용하여 초기 환경과 모델의 무작위성을 통제하였다. 이는 자율주행 모델이 시드에 따라 성능 편차가 크고, 안정적인 성능을 내기 위해 많은 학습 스텝이 요구되기 때문에, 실험 시간을 줄이고 일관된 비교를 가능하게 하기 위함이다. 학습은 총 1,000,000 step으로 고정하였고, SAC+HIL 구조에서는 초기 50,000 step 동안만 인간의 개입이 허용되었다.

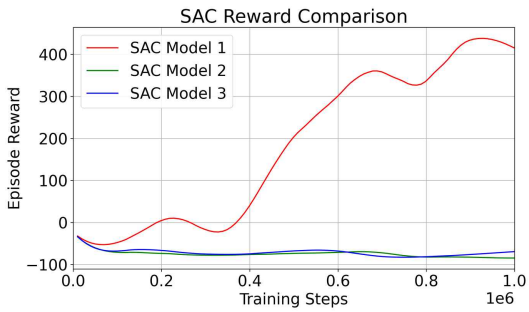

그림 3. SAC 모델의 학습 성능 비교

Figure 3. Performance comparison of SAC models

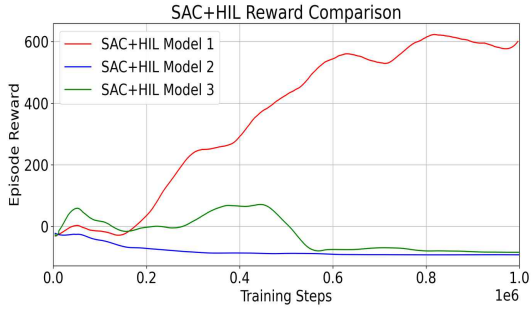

그림 4. SAC+HIL 모델의 학습 성능 비교

Figure 4. Performance comparison of SAC+HIL models

[그림 3]과 [그림 4]는 각각 SAC 모델과 SAC+HIL 모델의 학습 곡선을 나타낸다.

4.1 학습 성능 비교

SAC 실험 결과, 총 3개의 실험 중 하나는 평균 리워드가 400 이상까지 상승하며 안정적인 성능을 보였다. 반면 나머지 두 실험에서는 평균 리워드가 −70 내외에 머무르며 학습 성과가 매우 제한적이었다. 이는 SAC 알고리즘이 동일한 조건에서도 초기 탐색 과정에서 불안정성을 가질 수 있음을 보여준다.

SAC+HIL 실험에서는 한 실험에서 리워드가 600 이상까지 도달하며 가장 높은 성능을 기록하였다. 그러나 다른 두 실험에서는 리워드가 낮은 수준에서 정체되었으며, SAC와 동일하게 낮은 성과를 보이기도 하였다. HIL 방식이 일부 실험에서 유의미한 효과를 보였지만, 전반적으로 일관된 성능 향상을 보장하지는 못하였다.

4.2 결과 분석

본 연구의 SAC+HIL 구조에서 사람의 개입 데이터를 별도로 관리하거나 우선 샘플링하는 전략을 사용하지 않았다. 대신 개입 데이터를 에이전트의 일반적인 경험과 동일한 replay buffer에 저장하였으며, 이로 인해 사람의 유익한 행동 데이터가 다른 데이터에 묻혀 효과적으로 학습되지 않았을 가능성이 있다. 또한 사람의 입력은 키보드 기반의 직관적인 제어로 이루어졌으며, 이는 항상 최적의 행동을 제공한다고 보기 어렵다. 일부 상황에서는 사람의 개입이 오히려 비효율적인 행동을 유도하고, 해당 행동이 버퍼에 저장되어 학습을 방해했을 가능성도 존재한다.

마지막으로, 개입 후 학습이 이루어지는 빈도와 규모 역시 성능에 영향을 미쳤을 수 있다. 본 실험에서는 개입이 발생한 경우에만 1,000 step 단위로 학습을 수행하였고, 이후 50,000 step의 학습 과정을 진행하였지만, 전체 replay buffer에서 HIL 데이터의 비중이 낮은 경우 학습 효과가 제한되었을 수 있다.

5. 결론

본 연구에서는 자율주행 환경에서 강화학습의 초기 불안정성을 보완하기 위해, 사람의 개입을 학습 과정에 자연스럽게 통합하는 SAC+HIL 구조를 제안하였다. 실험을 통해 이 방식이 일부 상황에서는 빠른 수렴과 높은 성능을 보였지만, 모든 실험에서 일관된 향상을 보이진 않았다. 이러한 결과는 개입 데이터가 일반 데이터와 함께 저장되고 학습되는 구조로 인해 효과적으로 반영되지 않았거나, 개입 방식의 한계로 인해 충분한 학습 신호를 제공하지 못했기 때문으로 해석된다.

향후에는 사람 개입 데이터를 명시적으로 구분하거나 우선 반영할 수 있는 샘플링 전략을 도입할 계획이며, 개입 데이터가 항상 더 효율적이지 않을 수 있다는 점을 고려하여 그 효과를 동적으로 판단하고 반영할 수 있는 학습 구조 또한 함께 설계할 예정이다. 이러한 개선 방향을 바탕으로, 다양한 환경과 알고리즘에 HIL 기법을 확장 적용하는 연구를 이어갈 것이다.

ACKNOWLEDGMENT

“이 논문은 2023년도부터 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 연구임”(No.2023-0-00076, SW 중심대학(동아대학교))

참고문헌

[1] B. R. Kiran, I. Sobh, V. Talpaert, P. Mannion, A. Al Sallab, S. Yogamani, and P. Pérez, “Deep reinforcement learning for autonomous driving: A survey,” IEEE Transactions on Intelligent Transportation Systems, vol. 23, no. 6, pp. 4909-4926, 2021.

[2] A. Kendall, J. Hawke, D. Janz, P. Mazur, D. Reda, J. Allen, et al., “Learning to drive in a day,” in Proceedings of the IEEE International Conference on Robotics and Automation (ICRA), 2019.

[3] C. Zhang, Y. Wu, and B. Plank, “Curriculum learning for natural language understanding with human−in−the−loop,” arXiv preprint, arXiv:1910.07241, 2019.

[4] J. MacGlashan, M. K. Ho, R. Loftin, B. Peng, D. L. Roberts, M. E. Taylor, and M. L. Littman, “Interactive learning from policy−dependent human feedback,” in Proceedings of the International Conference on Machine Learning (ICML), 2017.

[5] T. Haarnoja, A. Zhou, P. Abbeel, and S. Levine, “Soft actor−critic: Off−policy maximum entropy deep reinforcement learning with a stochastic actor,” in Proceedings of the International Conference on Machine Learning (ICML), 2018.

[6] M. Andrychowicz, B. Baker, M. Chociej, R. Józefo

wicz, B. McGrew, J. Pachocki, et al., "Learning dexterous in-hand manipulation," International Journal of Robotics Research, vol. 39, no. 1, pp. 3-20, 2020.
[7] Christiano, P. F., Leike, J., Brown, T., Martic, M., Legg, S., & Amodei, D. (2017). Deep reinforcement learning from human preferences. In Advances in Neural Information Processing Systems (NeurIPS).

[8] Rhinehart, N., Kitani, K. M., & Levine, S. (2022). Imitation Is Not Enough: Robustifying Imitation with Reinforcement Learning for Challenging Driving Scenarios. arXiv preprint arXiv:2212.11419.